Projeto final — MATD39

Análise Descritiva e Exploratória de Dados A

Grupos de 5 integrantes · Entrega do relatório: **15/12/2026** · Linguagem: Python ou R

---

1 · Objeto

O projeto final consiste na análise descritiva e exploratória de um conjunto de dados públicos brasileiros, a partir de uma pergunta central definida para cada conjunto. A resposta deve se apoiar nas medidas, tabelas e gráficos produzidos.

Serão entregues um **relatório** e uma **arguição oral**.

---

2 · Organização

- São **seis conjuntos de dados**, um por grupo. Cada grupo tem **5 integrantes**. A ordem de escolha é sorteada, e cada grupo escolhe o seu quando chegar a sua vez.
- A linguagem é livre: **Python ou R**.
- Os seis arquivos são publicados junto com este enunciado e ficam disponíveis em **URL fixa** durante todo o projeto. O arquivo deve ser lido diretamente do link — `read.csv` em R, `pd.read_csv` em Python.
- **Entrega do relatório:** 15 de dezembro de 2026. O relatório e o código devem ser enviados para o diretório do grupo no Google Drive da disciplina.
- **Arguição oral:** realizada remotamente, com horário agendado previamente com cada grupo.
- **Não há entregas intermediárias.**

---

3 · Conteúdo do relatório

O relatório deve conter as dez saídas abaixo, comuns aos seis grupos. Análises adicionais são permitidas.

#	saída
1	Dimensão da tabela (linhas e colunas), tipos das variáveis e percentual de valores faltantes
2	Média, mediana, quartis, desvio padrão, coeficiente de variação e IQR de **uma** variável numérica
3	Frequência e proporção de **uma** variável categórica, com gráfico de barras
4	Histograma **e** boxplot da **mesma** variável
5	A mesma medida calculada em **dois ou mais subgrupos**
6	Assimetria de Pearson e curtose
7	Quantos casos têm $\|z\| > 2$ e **quais são** — as linhas devem ser nomeadas

#	saída
8	Correlação entre **duas ou mais** variáveis numéricas
9	Dois achados escritos, sendo **um deles não previsto**
10	Resposta à pergunta central em **um parágrafo**

Os itens 9 e 10 referem-se à interpretação dos resultados; os demais, ao cálculo e à apresentação.

O **código** que gerou os resultados (notebook ou script, executável) deve ser entregue junto com o relatório.

---

4 · Avaliação

componente	peso
relatório	60%
arguição oral	40%

A arguição oral é realizada por grupo, com duração de 30 minutos e perguntas sorteadas no momento. Cada integrante responde sobre a parte que lhe couber. A nota individual é obtida do cruzamento entre a nota do grupo e o desempenho na arguição.

Critérios:

- **Suficiente** — as dez saídas do item 3 foram entregues.
- **Ótimo** — além das saídas, o grupo apresenta análise crítica dos resultados: interpretação, verificação e justificativa do que os dados mostram.

---

5 · Uso de inteligência artificial

O uso de ferramentas de inteligência artificial (ChatGPT, Claude, Copilot ou equivalentes) é permitido, sem restrição de ferramenta. **É obrigatório declarar esse uso.**

O relatório deve conter uma seção **"Uso de IA"**, informando:

- em que **etapa** a ferramenta foi utilizada;
- com que **finalidade**;
- qual foi o **aproveitamento** da resposta — utilizada, corrigida ou descartada.

> Exemplo: "A ferramenta foi utilizada na redação do código do boxplot por região, por não sabermos separar as cores por grupo; a resposta foi utilizada sem alteração. Foi utilizada também na interpretação do coeficiente de variação, cujo resultado estava incorreto — confundia o coeficiente com o desvio padrão; a interpretação foi refeita."

O uso de IA não substitui o que o grupo precisa saber responder na arguição. Ainda que trechos do código tenham sido gerados com auxílio de IA, a arguição pode incluir perguntas sobre qualquer parte do

trabalho — o que determinada função ou comando faz, como se lê um resultado, por que uma medida foi escolhida.

As perguntas da arguição são sorteadas no momento, e cada integrante responde sobre a parte que lhe couber. Por esse motivo, **todos os membros da equipe devem estar aptos a responder sobre qualquer parte do trabalho**.

Anexo — os seis conjuntos de dados

Cada ficha apresenta a pergunta central, o link do arquivo, a descrição do conjunto e o dicionário das colunas. Todos os arquivos estão em CSV e podem ser lidos diretamente do link.

Os conjuntos são provenientes de fontes oficiais brasileiras e foram previamente tratados. A descrição do conteúdo de cada arquivo integra o item 1 do relatório.

1 · Transporte — acidentes em rodovias federais

Pergunta central: acidentes em rodovia federal são mais perigosos de dia ou de noite?

Arquivo: `acidentes_prf_2024.csv` — [URL do CSV — a definir]

Descrição. Acidentes registrados pela Polícia Rodoviária Federal nas rodovias federais do país em 2024: **73.201 acidentes**, 29 colunas. Cada linha corresponde a um acidente, com data, hora, local, causa, tipo e resultado (mortos, feridos, ilesos).

Dicionário dos campos

coluna	o que é
`id`	Identificador do acidente
`data_inversa`	Data do acidente
`dia_semana`	Dia da semana
`horario`	Hora do acidente, no formato HH:MM:SS
`uf`	Estado (sigla)
`br`	Número da rodovia federal (ex.: 101, 116)
`km`	Quilômetro da rodovia onde ocorreu
`municipio`	Município
`causa_acidente`	Causa provável registrada (69 valores, ex.: "Reação tardia ou ineficiente do condutor")
`tipo_acidente`	Tipo de acidente (17 valores, ex.: "Colisão traseira", "Saída de leito carroçável")
`classificacao_acidente`	Gravidade: Sem Vítimas, Com Vítimas Feridas ou Com Vítimas Fatais
`fase_dia`	Momento do dia: Pleno dia, Plena Noite, Anoitecer, Amanhecer
`sentido_via`	Sentido da via: Crescente, Decrescente, Não Informado
`condicao_metereologica`	Clima no momento: Céu Claro, Nublado, Chuva, Sol, Garoa/Chuvisco, Nevoeiro/Neblina, Vento, Granizo, Neve, Ignorado
`tipo_pista`	Simples, Dupla ou Múltipla
`tracado_via`	Traçado da via (Reta, Curva, Aclive, Declive; pode combinar mais de um)
`uso_solo`	Sim se o trecho está em área urbana, Não se rural
`pessoas`	Total de pessoas envolvidas
`mortos`	Pessoas mortas
`feridos_leves`	Feridos leves
`feridos_graves`	Feridos graves
`ilesos`	Pessoas ilesas

coluna	o que é
`ignorados`	Pessoas sem estado informado
`feridos`	Feridos leves + graves *(derivada)*
`veiculos`	Veículos envolvidos
`latitude`	Coordenada geográfica
`longitude`	Coordenada geográfica
`hora`	Hora do dia em número decimal (03:56 corresponde a 3,93) *(derivada)*
`total_vitimas`	Feridos + mortos *(derivada)*

---

2 · Trabalho — salários por ocupação em São Paulo

Pergunta central: quais ocupações pagam melhor em São Paulo?

Arquivo: `caged_sp_2024_01.csv` — [URL do CSV — a definir]

Descrição. Admissões registradas no **Novo CAGED** (registro oficial de emprego do Ministério do Trabalho) no estado de São Paulo em janeiro de 2024: **633.990 admissões**, 10 colunas. Cada linha corresponde a uma pessoa contratada, com ocupação, escolaridade, idade e salário.

Dicionário dos campos

coluna	o que é
`municipio`	Município do estabelecimento (644 municípios)
`ocupacao`	Nome da ocupação (2.045 ocupações distintas)
`categoria`	Tipo de vínculo: Geral, Temporário, Aprendiz, Intermitente, Prazo determinado, Rural de pequeno prazo
`secao`	Seção da atividade econômica (21 seções, ex.: Comércio, Construção, Indústria de transformação)
`grau_instrucao`	Escolaridade (12 níveis, de Analfabeto a Doutorado)
`raca_cor`	Raça/cor declarada (Branca, Parda, Preta, Amarela, Indígena, Não informada, Não Identificado)
`sexo`	Homem, Mulher, Não Identificado
`idade`	Idade em anos (14 a 88)
`horas_contratuais`	Jornada semanal contratada
`salario`	Salário mensal, em reais

3 · Segurança — ocorrências criminais por município

Pergunta central: a criminalidade aumentou no Brasil entre 2015 e 2025?

Arquivo: `seguranca_publica_municipio.csv` — [URL do CSV — a definir]

Descrição. Registros de ocorrências do **SINESP** (Sistema Nacional de Estatísticas de Segurança Pública, do Ministério da Justiça), por município e por ano: **667.559 linhas**, 5 colunas. Cada linha corresponde ao total de casos de um indicador, em um município, em um ano. Cobre 5.297 municípios das 27 unidades da federação.

Os dados abrangem de 2015 a 2026, e **2026 está incompleto** — o ano ainda não havia terminado quando a base foi extraída.

Dicionário dos campos

coluna	o que é
`uf`	Estado (sigla)
`municipio`	Município
`ano`	Ano do registro (2015 a 2026)
`indicador`	Tipo de ocorrência — 10 valores, listados abaixo
`casos`	Número de casos registrados

Os 10 indicadores: Feminicídio · Homicídio doloso · Lesão corporal seguida de morte · Mandado de prisão cumprido · Morte no trânsito ou em decorrência dele (exceto homicídio doloso) · Mortes a esclarecer (sem indício de crime) · Roubo seguido de morte (latrocínio) · Suicídio · Tentativa de homicídio · Tentativa de feminicídio.

---

4 · Saúde — mortalidade infantil por município

Pergunta central: a mortalidade infantil é maior no interior ou nas capitais?

Arquivo: `mortalidade_infantil_municipio_2022.csv` — [URL do CSV — a definir]

Descrição. Nascimentos e óbitos de crianças menores de 1 ano em 2022, por município, a partir do **SINASC** (registro de nascidos vivos) e do **SIM** (registro de óbitos): **3.299 municípios**, 11 colunas. Foram mantidos os municípios com pelo menos 100 nascidos vivos no ano.

Dicionário dos campos

coluna	o que é
`codigo_ibge`	Código do município no IBGE
`municipio`	Nome do município
`uf`	Estado (sigla)
`regiao`	Nordeste, Sudeste, Sul, Norte, Centro-Oeste
`capital`	Capital ou Interior
`populacao`	População do município
`nascidos_vivos`	Nascidos vivos em 2022
`obitos_infantis`	Óbitos de crianças menores de 1 ano em 2022
`taxa_mortalidade_infantil`	Óbitos por mil nascidos vivos
`peso_medio_nascer`	Peso médio ao nascer, em gramas
`proporcao_baixo_peso`	Proporção de nascidos com menos de 2.500 g

5 · Desmatamento — alertas na Amazônia Legal

Pergunta central: o desmatamento na Amazônia aumentou em 2025?

Arquivo: `desmatamento_amazonia_alertas.csv` — [URL do CSV — a definir]

Descrição. Alertas de desmatamento e degradação do sistema **DETER**, do INPE, na Amazônia Legal: **466.707 alertas**, 9 colunas. Cada linha corresponde a um alerta — uma área detectada por satélite, com data, município e tipo de alteração. Abrange de 2016 a 2026.

Dicionário dos campos

coluna	o que é
`data`	Data do alerta
`ano`	Ano da data do alerta (2016 a 2026)
`mes`	Mês (1 a 12)
`ano_prodes`	Ano de referência do PRODES, que mede de agosto de um ano a julho do seguinte
`uf`	Estado (sigla), dentro da Amazônia Legal
`municipio`	Município
`codigo_municipio`	Código do município no IBGE
`classe`	Tipo de alteração detectada — 8 valores, listados abaixo
`area_km2`	Área do alerta, em km²

As 8 classes: `DESMATAMENTO_CR` (corte raso, a área foi totalmente desmatada) · `DESMATAMENTO_VEG` (desmatamento com vegetação) · `DEGRADACAO` (floresta degradada, não removida) · `CICATRIZ_DE_QUEIMADA` (marca de queimada) · `MINERACAO` (garimpo) · `CORTE_SELETIVO` (retirada de madeira) · `CS_DESORDENADO` e `CS_GEOMETRICO` (alertas com problema de geometria).

---

6 · Chuvas — leituras diárias das estações do INMET

Pergunta central: está chovendo menos nas estações do INMET?

Arquivo: `chuvas_diaria_estacao.csv` — [URL do CSV — a definir]

Descrição. Leituras diárias das estações meteorológicas do **INMET** no Brasil, de 2010 a 2020: **378.364 linhas**, 12 colunas. Cada linha corresponde a um dia de uma estação, com a chuva acumulada e a temperatura média.

Dicionário dos campos

coluna	o que é
`data`	Data da leitura (2010-01-01 a 2020-12-31)
`ano`	Ano
`codigo_estacao`	Código da estação do INMET
`nome_estacao`	Nome da estação
`uf`	Estado (sigla)
`regiao`	N, NE, CO, SE, S
`latitude`	Coordenada geográfica
`longitude`	Coordenada geográfica
`altitude`	Altitude da estação, em metros
`precipitacao_mm`	Chuva acumulada no dia, em milímetros (vazio quando não há leitura)
`horas_lidas`	Quantas horas do dia a estação registrou (0 a 24)
`temperatura_media_c`	Temperatura média do dia, em °C (vazio quando não há leitura)