Projeto final — MATD39

Análise Descritiva e Exploratória de Dados A

Grupos de 5 integrantes · Entrega do relatório: **15/12/2026** · Linguagem: Python ou R

---

1 · Objeto

O projeto final consiste na análise descritiva e exploratória de um conjunto de dados públicos brasileiros, a partir de uma pergunta central definida para cada conjunto. A resposta deve se apoiar nas medidas, tabelas e gráficos produzidos.

Serão entregues um **relatório** e uma **arguição oral**.

---

2 · Organização

- São **seis conjuntos de dados**, um por grupo. Cada grupo tem **5 integrantes**.
- A escolha do tema é por **ordem de manifestação**: o grupo que se manifestar primeiro fica com o tema. As escolhas são registradas numa **planilha de atribuição**, disponibilizada à turma — a planilha é o registro oficial de quem está com qual tema, e um tema já escolhido não pode ser pego por outro grupo.
- A linguagem é livre: **Python ou R**.
- Os seis arquivos ficam no **repositório do projeto no GitHub**, cujo link será divulgado no AVA da disciplina, e permanecem disponíveis durante todo o projeto. O arquivo deve ser lido diretamente do link — `read.csv` em R, `pd.read_csv` em Python.
- **Entrega do relatório:** 15 de dezembro de 2026. O relatório e o código devem ser enviados para um diretório em serviço de nuvem (Google Drive ou equivalente), cujo link será divulgado no AVA da disciplina.
- **Arguição oral:** realizada remotamente, com horário agendado previamente com cada grupo.
- **Não há entregas intermediárias.**

---

3 · Conteúdo do relatório

O relatório deve conter as dez saídas abaixo, comuns aos seis grupos. Análises adicionais são permitidas.

#	saída
1	Dimensão da tabela (linhas e colunas), tipos das variáveis e percentual de valores faltantes
2	Média, mediana, quartis, desvio padrão, coeficiente de variação e IQR de **uma** variável numérica
3	Frequência e proporção de **uma** variável categórica, com gráfico de barras
4	Histograma **e** boxplot da **mesma** variável

#	saída
5	A mesma medida calculada em **dois ou mais subgrupos**
6	Assimetria de Pearson e curtose
7	Quantos casos têm $\|z\| > 2$ e **quais são** — as linhas devem ser nomeadas
8	Correlação entre **duas ou mais** variáveis numéricas
9	Dois achados escritos, sendo **um deles não previsto**
10	Resposta à pergunta central em **um parágrafo**

Os itens 9 e 10 referem-se à interpretação dos resultados; os demais, ao cálculo e à apresentação.

O **código** que gerou os resultados (notebook ou script, executável) deve ser entregue junto com o relatório.

---

4 · Avaliação

componente	peso
relatório	60%
arguição oral	40%

A arguição oral é realizada por grupo, com duração de 30 minutos e perguntas sorteadas no momento. Cada integrante responde sobre a parte que lhe couber. A nota individual é obtida do cruzamento entre a nota do grupo e o desempenho na arguição.

Critérios:

- **Suficiente** — as dez saídas do item 3 foram entregues.
- **Ótimo** — além das saídas, o grupo apresenta análise crítica dos resultados: interpretação, verificação e justificativa do que os dados mostram.

---

5 · Uso de inteligência artificial

O uso de ferramentas de inteligência artificial (ChatGPT, Claude, Copilot ou equivalentes) é permitido, sem restrição de ferramenta. **É obrigatório declarar esse uso.**

O relatório deve conter uma seção **"Uso de IA"**, informando:

- em que **etapa** a ferramenta foi utilizada;
- com que **finalidade**;
- qual foi o **aproveitamento** da resposta — utilizada, corrigida ou descartada.

> Exemplo: "A ferramenta foi utilizada na redação do código do boxplot por região, por não sabermos separar as cores por grupo; a resposta foi utilizada sem alteração. Foi utilizada também na interpretação do coeficiente de

> variação, cujo resultado estava incorreto — confundia o coeficiente com o desvio padrão; a interpretação foi refeita."

O uso de IA não substitui o que o grupo precisa saber responder na arguição. Ainda que trechos do código tenham sido gerados com auxílio de IA, a arguição pode incluir perguntas sobre qualquer parte do trabalho — o que determinada função ou comando faz, como se lê um resultado, por que uma medida foi escolhida.

As perguntas da arguição são sorteadas no momento, e cada integrante responde sobre a parte que lhe couber. Por esse motivo, **todos os membros da equipe devem estar aptos a responder sobre qualquer parte do trabalho**.

Anexo — os seis conjuntos de dados

Cada ficha apresenta a pergunta central, o arquivo, a descrição do conjunto e o dicionário das colunas. Todos os arquivos estão em CSV, ficam no **repositório do projeto no GitHub** (link divulgado no AVA) e podem ser lidos diretamente do link.

Os conjuntos são provenientes de fontes oficiais brasileiras e foram previamente tratados. A descrição do conteúdo de cada arquivo integra o item 1 do relatório.

---

1 · Transporte — acidentes em rodovias federais

Pergunta central: acidentes em rodovia federal são mais perigosos de dia ou de noite?

Arquivo: `acidentes_prf_2024.csv` — [link no repositório do GitHub — a divulgar]

Descrição. Acidentes registrados pela Polícia Rodoviária Federal nas rodovias federais do país em 2024: **73.201 acidentes**, 29 colunas. Cada linha corresponde a um acidente, com data, hora, local, causa, tipo e resultado (mortos, feridos, ilesos).

Dicionário dos campos

coluna	o que é
`id`	Identificador do acidente
`data_inversa`	Data do acidente
`dia_semana`	Dia da semana
`horario`	Hora do acidente, no formato HH:MM:SS
`uf`	Estado (sigla)
`br`	Número da rodovia federal (ex.: 101, 116)
`km`	Quilômetro da rodovia onde ocorreu
`municipio`	Município
`causa_acidente`	Causa provável registrada (69 valores, ex.: "Reação tardia ou ineficiente do condutor")
`tipo_acidente`	Tipo de acidente (17 valores, ex.: "Colisão traseira", "Saída de leito carroçável")
`classificacao_acidente`	Gravidade: Sem Vítimas, Com Vítimas Feridas ou Com Vítimas Fatais
`fase_dia`	Momento do dia: Pleno dia, Plena Noite, Anoitecer, Amanhecer
`sentido_via`	Sentido da via: Crescente, Decrescente, Não Informado
`condicao_metereologica`	Clima no momento: Céu Claro, Nublado, Chuva, Sol, Garoa/Chuvisco, Nevoeiro/Neblina, Vento, Granizo, Neve, Ignorado
`tipo_pista`	Simples, Dupla ou Múltipla
`tracado_via`	Traçado da via (Reta, Curva, Aclive, Declive; pode combinar mais de um)
`uso_solo`	Sim se o trecho está em área urbana, Não se rural
`pessoas`	Total de pessoas envolvidas
`mortos`	Pessoas mortas
`feridos_leves`	Feridos leves
`feridos_graves`	Feridos graves
`ilesos`	Pessoas ilesas

coluna	o que é
`ignorados`	Pessoas sem estado informado
`feridos`	Feridos leves + graves *(derivada)*
`veiculos`	Veículos envolvidos
`latitude`	Coordenada geográfica
`longitude`	Coordenada geográfica
`hora`	Hora do dia em número decimal (03:56 corresponde a 3,93) *(derivada)*
`total_vitimas`	Feridos + mortos *(derivada)*

---

2 · Trabalho — salários por ocupação em São Paulo

Pergunta central: quais ocupações pagam melhor em São Paulo?

Arquivo: `caged_sp_2024_01.csv` — [link no repositório do GitHub — a divulgar]

Descrição. Admissões registradas no **Novo CAGED** (registro oficial de emprego do Ministério do Trabalho) no estado de São Paulo em janeiro de 2024: **633.990 admissões**, 10 colunas. Cada linha corresponde a uma pessoa contratada, com ocupação, escolaridade, idade e salário.

Dicionário dos campos

coluna	o que é
`municipio`	Município do estabelecimento (644 municípios)
`ocupacao`	Nome da ocupação (2.045 ocupações distintas)
`categoria`	Tipo de vínculo: Geral, Temporário, Aprendiz, Intermitente, Prazo determinado, Rural de pequeno prazo
`secao`	Seção da atividade econômica (21 seções, ex.: Comércio, Construção, Indústria de transformação)
`grau_instrucao`	Escolaridade (12 níveis, de Analfabeto a Doutorado)
`raca_cor`	Raça/cor declarada (Branca, Parda, Preta, Amarela, Indígena, Não informada, Não Identificado)
`sexo`	Homem, Mulher, Não Identificado
`idade`	Idade em anos (14 a 88)
`horas_contratuais`	Jornada semanal contratada
`salario`	Salário mensal, em reais

3 · Educação — cursos de ensino superior por município

Pergunta central: o ensino a distância domina o ensino superior brasileiro?

Arquivo: `educacao_superior_curso_2023.csv` — [link no repositório do GitHub — a divulgar]

Descrição. Cursos de graduação ofertados no **Censo da Educação Superior 2023**, do INEP: **660.571 cursos ofertados**, 15 colunas. Cada linha corresponde a um curso de uma instituição em um município — 3.495 municípios, 27 unidades da federação, 2.580 instituições e 46.248 cursos distintos. As contagens de alunos (`ingressantes`, `matriculas`, `concluintes`) são as do ano de 2023.

Um mesmo curso aparece em várias linhas quando a instituição o oferece em mais de um município.

Dicionário dos campos

coluna	o que é
`cod_ies`	Código da instituição de ensino superior
`cod_curso`	Código do curso dentro da instituição
`curso`	Nome do curso (ex.: Pedagogia, Direito, Enfermagem)
`cod_municipio`	Código do município no IBGE
`municipio`	Município onde o curso é ofertado
`uf`	Estado (sigla)
`regiao`	Norte, Nordeste, Sudeste, Sul, Centro-Oeste
`capital`	Capital ou Interior
`categoria`	Natureza administrativa: Pública federal, Pública estadual, Pública municipal, Privada com fins lucrativos, Privada sem fins lucrativos, Especial
`organizacao`	Universidade, Centro universitário, Faculdade, Instituto Federal de Educação, Ciência e Tecnologia, Centro Federal de Educação Tecnológica
`grau`	Bacharelado, Licenciatura, Tecnológico, Bacharelado e licenciatura, Não informado
`modalidade`	Presencial ou A distância
`ingressantes`	Alunos que ingressaram no curso em 2023
`matriculas`	Alunos matriculados no curso em 2023
`concluintes`	Alunos que concluíram o curso em 2023

4 · Saúde — mortalidade infantil por município

Pergunta central: a mortalidade infantil é maior no interior ou nas capitais?

Arquivo: `mortalidade_infantil_municipio_2022.csv` — [link no repositório do GitHub — a divulgar]

Descrição. Nascimentos e óbitos de crianças menores de 1 ano em 2022, por município, a partir do **SINASC** (registro de nascidos vivos) e do **SIM** (registro de óbitos): **3.299 municípios**, 11 colunas. Foram mantidos os municípios com pelo menos 100 nascidos vivos no ano.

Dicionário dos campos

coluna	o que é
`codigo_ibge`	Código do município no IBGE
`municipio`	Nome do município
`uf`	Estado (sigla)
`regiao`	Nordeste, Sudeste, Sul, Norte, Centro-Oeste
`capital`	Capital ou Interior
`populacao`	População do município
`nascidos_vivos`	Nascidos vivos em 2022
`obitos_infantis`	Óbitos de crianças menores de 1 ano em 2022
`taxa_mortalidade_infantil`	Óbitos por mil nascidos vivos
`peso_medio_nascer`	Peso médio ao nascer, em gramas
`proporcao_baixo_peso`	Proporção de nascidos com menos de 2.500 g

5 · Agricultura — produção agrícola por município

Pergunta central: qual estado tem a agricultura mais produtiva?

Arquivo: `producao_agricola_municipio_2023.csv` — [link no repositório do GitHub — a divulgar]

Descrição. Produção das lavouras temporárias em 2023, da **Produção Agrícola Municipal** (PAM), do IBGE: **35.919 lavouras**, 11 colunas. Cada linha corresponde a uma lavoura — a combinação de um município com um produto — em 5.484 municípios e 30 produtos, somando 90,2 milhões de hectares colhidos e R$ 690,9 bilhões em valor de produção.

Dicionário dos campos

coluna	o que é
`cod_municipio`	Código do município no IBGE
`municipio`	Nome do município
`uf`	Estado (sigla)
`uf_nome`	Nome do estado
`regiao`	Norte, Nordeste, Sudeste, Sul, Centro-Oeste
`produto`	Lavoura (30 produtos, ex.: Soja (em grão), Cana-de-açúcar, Mandioca, Feijão (em grão))
`area_plantada_ha`	Área plantada, em hectares
`area_colhida_ha`	Área efetivamente colhida, em hectares
`quantidade_t`	Quantidade produzida, em toneladas
`rendimento_kg_ha`	Rendimento médio da lavoura, em kg por hectare
`valor_mil_reais`	Valor da produção, em milhares de reais

O **rendimento** é a razão entre a quantidade produzida e a área colhida. Ele é calculado pelo IBGE para cada lavoura de cada município — não existe um rendimento do município nem do estado na tabela.

---

6 · Moradia — saneamento básico por município

Pergunta central: qual região do Brasil tem mais domicílios com esgoto adequado?

Arquivo: `saneamento_municipio_2022.csv` — [link no repositório do GitHub — a divulgar]

Descrição. Domicílios particulares permanentes ocupados, por tipo de esgotamento sanitário, do **Censo Demográfico 2022** (IBGE): **5.570 municípios**, 16 colunas. Cada linha corresponde a um município, com a contagem de domicílios em cada destino do esgoto e a proporção de esgoto adequado.

Dicionário dos campos

coluna	o que é
`cod_municipio`	Código do município no IBGE
`municipio`	Nome do município
`uf`	Estado (sigla)
`uf_nome`	Nome do estado
`regiao`	Norte, Nordeste, Sudeste, Sul, Centro-Oeste
`total_domicilios`	Domicílios particulares permanentes ocupados
`dom_adequado`	Domicílios com esgotamento adequado *(derivada)*
`dom_rede_geral_pluvial`	Domicílios com esgoto na rede geral ou pluvial
`dom_fossa_septica_ligada`	Domicílios com fossa séptica ou filtro ligado à rede
`dom_fossa_septica_nao_ligada`	Domicílios com fossa séptica ou filtro não ligado à rede
`dom_fossa_rudimentar`	Domicílios com fossa rudimentar ou buraco
`dom_vala`	Domicílios que lançam o esgoto em vala
`dom_rio`	Domicílios que lançam o esgoto em rio, lago, córrego ou mar
`dom_outra`	Domicílios com outra forma de esgotamento
`dom_sem_banheiro`	Domicílios sem banheiro nem sanitário
`pct_adequado`	Domicílios com esgotamento adequado, em % do total *(derivada)*

O esgotamento **adequado** é a classificação do IBGE: rede geral ou pluvial, ou fossa séptica ou filtro ligado à rede. As duas parcelas aparecem separadas nas colunas acima, e `dom_adequado` é a soma delas.